

## 基于改进灰狼优化支持向量回归的网络舆情预测

林 玲<sup>1,2,3</sup>, 陈福集<sup>1</sup>, 谢加良<sup>2,3</sup>, 李 凤<sup>2,3</sup>

(1. 福州大学 经济与管理学院, 福州 350108; 2. 集美大学 理学院, 厦门 361021;

3. 集美大学 大数据建模与智能计算研究所, 厦门 361021)

**摘 要** 网络舆情发展趋势预测对政府相关部门的舆情监测与管控有非常重要的参考意义。针对网络舆情的小样本特性, 同时考虑适用模型的时效性和准确度, 本文提出一种基于佳点集方法初始化、非线性参数控制以及对引领狼赋权的改进灰狼优化支持向量回归 (IGWO-SVR) 的网络舆情预测模型, 以“新冠肺炎”、“中国梦”等百度指数作为舆情数据样本进行了实证研究。对比实验结果显示, 改进后的灰狼优化算法有较强的全局搜索能力、较快的收敛速度以及较好的稳定性。IGWO-SVR 网络舆情预测模型有较为突出的准确性与稳定性, 能够为政府舆情管控部门提供较好的决策参考。

**关键词** 网络舆情; 灰狼优化; 支持向量机; 佳点集; 新冠肺炎

## Prediction of network public opinion based on improved grey wolf optimized support vector machine regression

LIN Ling<sup>1,2,3</sup>, CHEN Fujun<sup>1</sup>, XIE Jialiang<sup>2,3</sup>, LI Feng<sup>2,3</sup>

(1. School of Economics and Management, Fuzhou University, Fuzhou 350108, China;

2. College of Science, Jimei University, Xiamen 361021, China;

3. Institute of Big Data Modeling and Intelligent Computing, Jimei University, Xiamen 361021, China)

**Abstract** The prediction of the development trend of internet public opinion is a very significant reference for monitoring and control of the network public opinion by the relevant government departments. On account of small sample characteristics of online public opinion and the needs for both accuracy and stability in the prediction model, in this paper, an improved grey wolf optimization algorithm (IGWO) based on the initialization of the good-point set method, nonlinear parameter control and the weighting of the leading wolf is proposed. Using IGWO to optimize the super parameters of SVM regression model, a network public opinion prediction model based on improved grey wolf optimized support vector machine regression (IGWO-SVR) is established. Empirical research is carried out with Baidu indexes such as COVID-19 as public opinion data samples. The experimental results of 12 test functions show that the improved grey wolf optimization algorithm has relatively strong global search ability, faster convergence speed and better stability. The IGWO-SVR model has relatively outstanding accuracy and stability in the prediction of the development trend of public opinion, which can provide better decision-making support for public opinion supervision department of government.

**收稿日期:** 2020-06-09

**作者简介:** 林玲 (1978–), 男, 汉, 福建福州人, 博士研究生, 研究方向: 大数据与网络舆情, E-mail: 35226938@qq.com; 陈福集 (1954–), 男, 汉, 博士生导师, 教授, 博士, 研究方向: 电子政务与网络舆情; 通信作者: 谢加良 (1981–), 男, 汉, 副教授, 研究方向: 计算智能与不确定信息决策, E-mail: xiejialiang@jmu.edu.cn; 李凤 (1980–), 女, 汉, 副教授, 研究方向: 模糊多属性决策。

**基金项目:** 国家自然科学基金 (71271056); 福建省软科学基金 (B19085); 福建省教育厅项目 (JT180263); 集美大学数字福建大数据建模与智能计算研究所开放基金

**Foundation item:** National Natural Science Foundation of China (71271056); Soft Science Research Program of Fujian Province (B19085); The Projects of Education Department of Fujian Province (JT180263); The Open Fund of Digital Fujian Big Data Modeling and Intelligent Computing

**中文引用格式:** 林玲, 陈福集, 谢加良, 等. 基于改进灰狼优化支持向量回归的网络舆情预测 [J]. 系统工程理论与实践, 2022, 42(2): 487–498.

**英文引用格式:** Lin L, Chen F J, Xie J L, et al. Prediction of network public opinion based on improved grey wolf optimized support vector machine regression[J]. Systems Engineering — Theory & Practice, 2022, 42(2): 487–498.

**Keywords** network public opinion; grey wolf optimization; support vector machine; good-point set; COVID-19

## 1 引言

在高度发达的互联网信息新时代,数以亿计的网民每天都能产生海量的数据信息.社会热点、焦点事件的相关信息经过网上大量传播,会左右广大网民的思想和行为,进而可能发展成为网络舆情.网络舆情尤其是负面、恶意的舆情在“意见领袖”和“网络推手”的操纵下,极易演化成社会极端事件,给国家安全、社会稳定带来严重影响.因此,及时、准确预测网络舆情发展趋势,有利于政府对舆情的有效监控和适时引导,以保障公共安全与社会和谐稳定.

从时间序列上看,网民对舆情事件的关注热度反映为网络舆情发展趋势.常见网络舆情预测方法有小波变换与差分自回归移动平均模型<sup>[1]</sup>、隐马尔科夫模型<sup>[2]</sup>、均值灰色模型<sup>[3]</sup>等统计学和灰色系统方法.由于网络舆情发展趋势的预测具有复杂性和非线性,采用传统统计学和灰色系统的方法具有一定的局限性,而机器学习方法基于非线性理论建模,可以更加准确地描述网络舆情变化.如,田世海等<sup>[4]</sup>构建舆情预测模型的贝叶斯结构,利用大量舆情案例数据集进行学习,建立自媒体舆情反转预测模型;杨茂青等<sup>[5]</sup>基于随机森林算法建立突发事件网络舆情演化预测模型,以微博和第三方舆情监测平台作为实验数据来源,结果验证模型有较高的拟合度和更低的误差值;魏德志、游丹丹等<sup>[6,7]</sup>提出基于改进的粒子群优化径向基神经网络和 BP (back propagation, BP) 神经网络模型用于网络舆情的发展趋势预测,取得较高的预测精度.这些机器学习方法弥补了传统统计学模型预测的不足,预测精度得到进一步提升,但也存在不足:如,贝叶斯算法的先验知识主观性较强,数值难以确定;随机森林在回归问题上,不能做出超越训练集数据范围的预测,噪音较大时容易过拟合;神经网络模型内部结构复杂,收敛慢,且较易陷入局部最优等.

网络舆情发展趋势具有多因素相互作用、复杂的非线性特征,波动性大,预测时点的样本量少,这使得机器学习中支持向量机 (support vector machine, SVM) 模型的应用优势凸显. SVM<sup>[8]</sup>是以统计学习理论为基础的机器学习算法,常用于解决模式识别与函数逼近问题,可分为支持向量分类 (support vector classification, SVC) 和支持向量回归 (support vector regression, SVR). SVR 能够很好地解决小样本、高维数以及特征与目标之间的复杂非线性关系的回归预测问题,具有建模过程简单、耗时少、预测结果准确等优势.但由于 SVR 模型中超参数值的设定对模型预测的精度影响显著,在网络舆情发展趋势预测等实际应用中,学者们通常采用遗传优化、粒子群优化、果蝇优化、人工蜂群优化等<sup>[9-11]</sup>智能算法优化 SVR 中的惩罚系数  $C$  和核心参数  $g$ ,以此提高 SVR 模型的性能.如,戴臻等<sup>[12]</sup>建立了一种基于布谷鸟搜索 (cuckoo search, CS) 算法优化支持向量机 (CS-SVM) 的网络热点话题预测模型,仿真结果证明 CS-SVM 模型可以较准确地描述热点话题的变化趋势,提高热点话题的预测精度.

灰狼优化<sup>[13,14]</sup> (grey wolf optimizer, GWO) 算法于 2014 年由 Mirjalili 等提出的一种新型启发式群体智能方法,与其他群智能方法相比,其参数较少,且初始搜索不要求导信息.该方法简单、易用、灵活、可扩展性能好. GWO 在搜索过程中能够较好地实现勘探和开发之间的正确平衡,进一步优化支持向量机中的参数,可广泛地应用于信号分类、时间序列预测、网络和图像处理等领域<sup>[15-19]</sup>.同时,针对经典 GWO 在寻优过程可能于陷入局部最优等不足之处,学者们提出了各种不同的改进方法且得到了成功的应用<sup>[20-22]</sup>.

为提高经典 GWO 算法的优化性能,本文提出一种基于佳点集方法初始化、非线性参数控制以及对引领狼赋权的改进灰狼优化算法,进而构建改进灰狼优化支持向量回归 (IGWO-SVR) 的网络舆情预测模型,以“新冠肺炎”、“中国梦”等百度指数作为舆情数据样本进行实证研究.

## 2 相关理论基础

### 2.1 网络舆情预测

网络舆情是指网民大众对社会热点问题不同看法的网络舆论,是社会舆论通过互联网传播的有较强影响力、倾向性的言论和观点,具有发展速度快、波及广、影响范围大等特点.通常情况下,可以将网络舆情发展过程划分为孕育、扩散、变换、衰减等四个阶段<sup>[23]</sup>.其中,舆情热点传播扩散过程中,在多种因素共同作用

下,可能呈现多点多次爆发,并不断演化扩散,进而有可能失控引发极端事件。

影响网络舆情发展的不确定因素众多、关系复杂,但舆情发展趋势是一个时间序列,公众对舆情的关注度是舆情趋势的有效度量。百度指数和微指数是常用的网络舆情趋势指标。百度指数以海量网民行为数据为基础,加权统计了舆情关键词搜索趋势,可靠、准确反映舆情发展动向;微指数是根据新浪微博对关键词的提及量、阅读量和互动量等科学计算得到的综合指数。本文采用百度指数作为舆情数据样本的来源,反映网民对互联网舆情的关注和热议程度。

## 2.2 支持向量回归(SVR)原理

SVR<sup>[8]</sup>主要思想是,引入核函数将样本空间中非线性回归映射为高维空间中的线性回归问题,即寻找一个最优分类超平面,使得所有训练样本离该最优超平面的误差最小。基本原理如下:

对于给定的样本数据集  $V = (x_i, y_i), i = 1, 2, \dots, n, x_i \in R^d, y_i \in R^d$ , 这里,  $x_i$  为输入样本值,  $y_i$  为对应的输出值,  $n$  为训练样本数, 建立高维特征空间的回归模型如公式(1)所示。

$$y = \omega \cdot \phi(x) + b, \quad (1)$$

其中,  $x_i \in R^d$  样本集,  $d$  为输入变量的维度;  $\phi(x)$  为输入输出的映射关系;  $\omega$  和  $b$  分别为回归权重和偏置值;  $y$  为待拟合的预测函数值, 通过惩罚风险函数  $R(C)$  得到。

$$\begin{cases} R(C) = C \frac{1}{n} \sum_{i=1}^n L_{\varepsilon}(y) + \frac{1}{2} \|\omega\|^2, \\ L_{\varepsilon}(y) = \begin{cases} |f(x) - y| - \varepsilon & (|f(x) - y| > \varepsilon), \\ 0 & (|f(x) - y| \leq \varepsilon), \end{cases} \end{cases} \quad (2)$$

其中,  $\|\omega\|^2$  为惩罚函数;  $C$  为惩罚系数,  $\varepsilon$  为不敏感函数参数;  $L_{\varepsilon}(y)$  不敏感损失函数。引入松弛变量  $\delta$ ,  $\delta^* > 0$ , 则公式(2)等价于:

$$\min \frac{1}{2} \|\omega\|^2 + \sum_{i=1}^n (\delta_i + \delta_i^*), \quad \text{s.t.} \begin{cases} y_i - [\omega \cdot \phi(x)] - b \leq \varepsilon + \delta_i, & (\delta_i \geq 0), \\ [\omega \cdot \phi(x)] + b - y_i \leq \varepsilon + \delta_i^*, & (\delta_i^* \geq 0), \end{cases} \quad (3)$$

引入 Lagrange 乘子  $a_i$  和  $a_i^*$  构造 pLagrange 函数, 公式(3)优化的对偶问题为:

$$\max \sum_{i=1}^n y_i (a_i - a_i^*) - \varepsilon \sum_{i=1}^n (a_i + a_i^*) - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n (a_i - a_i^*) (a_j - a_j^*) K(x_i, x_j), \quad \text{s.t.} \begin{cases} \sum_{i=1}^n (a_i - a_i^*) = 0, \\ 0 \leq a_i, a_i^* \leq C, \end{cases} \quad (4)$$

其中,  $K(x_i, x)$  为核函数, 选用宽度为  $\sigma$  的高斯径向基核函数, 利用 KKT (Karush-Kuhn-Tucker) 条件, 得到最终的 SVR 函数公式(5):

$$\begin{cases} f(x) = \sum_{i=1}^n (a_i - a_i^*) K(x_i, x) + b, \\ K(x_i, x) = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma}\right) = \exp(-g\|x_i - x_j\|^2), \end{cases} \quad (5)$$

其中,  $g$  为核函数的参数, 它与惩罚系数  $C$  是直接影响 SVR 预测性能两个重要超参数。

## 2.3 灰狼优化(GWO)算法基本原理

GWO<sup>[13,14]</sup>通过模拟灰狼群体等级制度和狼群捕食策略, 不断迭代寻找最优解。当灰狼寻优算法用于优化连续函数时, 狼群数量设置为  $N$ , 其中将  $\alpha, \beta, \delta$  狼分别定义为第一、二、三等级, 剩下的属于最低等级的  $\omega$  狼。设搜索空间维度为  $d$ , 在  $d$  维空间中第  $i$  头狼的位置定义为:  $X_i = (x_{i1}, x_{i2}, \dots, x_{id})$ , 灰狼群体捕猎活动过程中, 下层等级必须服从上层等级的指示和领导。狼群捕猎行为包括搜索、靠近、包围、猎捕、攻击等多个步骤。优化过程主要的两个步骤为包围和猎捕:

1) 包围。对于优化问题, 猎物的最终位置是其全局最优解, 灰狼根据与猎物的距离  $D$  可用公式(6)表示, 狼群根据猎物位置和与猎物的距离更新其位置用公式(7)表示:

$$D = |C^* \cdot X_p(t) - X(t)|, \quad (6)$$

$$X(t+1) = X_p(t) - A \cdot D. \quad (7)$$

公式 (6) 和 (7) 中,  $t$  表示迭代次数,  $X_p(t)$  表示在第  $t$  次迭代时猎物的位置,  $X(t)$  表示在第  $t$  次迭代时灰狼个体的位置;  $A$  是收敛因子,  $C^*$  是系数常量, 通过调整这两个向量, 灰狼可以到达猎物周围的不同位置, 其计算方法用公式 (8) 至 (10) 表示:

$$a = 2 - t/\text{Maxiter}, \quad (8)$$

$$A = 2ar_1 - a, \quad (9)$$

$$C^* = 2r_2, \quad (10)$$

其中,  $r_1, r_2 \in [0, 1]$  是随机向量,  $t$  是当前迭代次数,  $\text{Maxiter}$  为最大迭代次数.

2) 猎捕. 灰狼包围猎物后, 开始捕猎, 一般由  $\alpha, \beta, \delta$  引导,  $\omega$  根据  $\alpha, \beta, \delta$  的位置更新自己的位置, 计算如公式 (11) 至 (13) 所示:

$$\begin{aligned} D_\alpha &= |C_1 \cdot X_\alpha - X|, \\ D_\beta &= |C_2 \cdot X_\beta - X|, \\ D_\delta &= |C_3 \cdot X_\delta - X|, \end{aligned} \quad (11)$$

$$\begin{cases} X_1 = X_\alpha - A_1 \cdot D_\alpha, \\ X_2 = X_\beta - A_2 \cdot D_\beta, \\ X_3 = X_\delta - A_3 \cdot D_\delta, \end{cases} \quad (12)$$

$$X(t+1) = \frac{X_1 + X_2 + X_3}{3}, \quad (13)$$

其中,  $D_\alpha, D_\beta, D_\delta$  分别表示  $\alpha, \beta, \delta$  狼与  $\omega$  狼的距离;  $X(t+1)$  为每次更新后的灰狼位置. 根据上述方法不断迭代直到满足终止条件, 得到优化目标最优解.

### 3 改进灰狼优化支持向量机回归的网络舆情预测模型 (IGWO-SVR)

网络舆情热度趋势曲线是典型的时间序列, 具有线性不可分的特点. 利用 SVR 模型进行热度趋势预测时, 本质是通过核函数将舆情热度样本点数据从低维空间投射到更高维空间, 将非线性问题转换为线性问题. 惩罚系数  $C$  和核函数的参数  $g$  直接影响舆情趋势预测结果. 如公式 (5) 所示, 惩罚系数  $C$  反映预测模型对超出舆情热度曲线  $\varepsilon$  管道样本数据的惩罚度, 其值影响预测模型的复杂性和稳定性. 如果  $C$  过小, 对超出  $\varepsilon$  管道的样本数据惩罚力度小, 热度预测曲线的振荡增大, 训练误差变大, 导致在实际预测中拟合的精度不高, 决策者难以判断舆情发展的准确趋势; 如果  $C$  过大, 学习精度则相应提高, 但预测模型的泛化能力会变差, 可能导致预测结果完全偏离实际舆情走势, 误导舆情管控决策. 另外,  $C$  的值会影响到对样本中“离群点”的处理, 设定合适的  $C$  值能在一定程度上抵抗干扰, 保证预测模型的稳定性. 核函数的参数  $g$  则反映了支持向量之间的相关度.  $g$  值越小, 支持向量间的联系越松散, 学习的模型越复杂, 泛化能力就越差; 而  $g$  增大, 支持向量间的影响越强, 舆情预测模型就越难达到足够的精度. 因此, 舆情预测的 SVR 模型的复杂度、泛化能力, 取决于能否取到合适的  $(C, g)$  对. 由于经典灰狼优化算法在寻优化过程中容易陷入局部最优, 本文在已有相关研究的基础上提出一种基于佳点集方法初始化、非线性参数控制以及对引领狼赋权的改进灰狼优化算法 (IGWO). 通过 12 个测试函数的实验对比验证, 改进后的灰狼优化算法有较强的全局搜索能力、较快的收敛速度以及较好的稳定性能.

#### 3.1 改进灰狼优化算法

##### 3.1.1 佳点集初始化灰狼种群位置

在群智能优化算法中, 初始种群位置的分布状况会影响全局搜索速度和解的质量, 种群分布均匀和多样性有利于算法的寻优性能的提升<sup>[24]</sup>. 由于灰狼优化算法 (GWO) 的初始化采用的随机数, 使得灰狼初始位置的多样性难以保证. 因此, 本文引入佳点集对灰狼个体起始分布位置进行初始化.

佳点集理论由华罗庚先生<sup>[25]</sup>提出, 在群智能优化中得到了很好的应用<sup>[26,27]</sup>. 其基本原理可描述如下: 设  $G_d$  是维欧氏空间的单位立方体, 如果  $r \in G_d$ , 形如:

$$p_n(k) = \left\{ \left( \left\{ r_1^{(n)} \times k \right\}, \dots, \left\{ r_i^{(n)} \times k \right\}, \dots, \left\{ r_i^{(n)} \times k \right\} \right), 1 \leq k \leq n \right\}. \quad (14)$$

公式(14)中的  $\{r_i^{(n)} \times k\}$  是  $\{r_i^{(n)} \times k\}$  的小数部分,其偏差满足:

$$\phi(n) = C(r, \varepsilon)n^{-1+\varepsilon}. \quad (15)$$

公式(15)中,  $\varepsilon$  是任意的正数,  $C(r, \varepsilon)$  是只与  $r$  和  $\varepsilon$  有关的常数,则称  $p_n(k)$  为佳点集,  $r$  为佳点. 取:

$$\{r_k = \{2 \cos(2\pi k/p)\}, 1 \leq k \leq d\}, \quad (16)$$

其中,  $p$  是满足  $(p-3)/2 \geq d$  的最小素数. 文献[28]证明了:对于未知均匀分布的对象,随机取  $n$  个点的偏差为:

$$O(n^{-1/2}(\log \log n)^{1/2}). \quad (17)$$

如果用佳点集方法取  $n$  个点,其偏差为  $O(n^{-1+\varepsilon})$ , 其中  $n$  是样本数,  $\varepsilon$  是任意小的正数. 因此,佳点集的方法选点的偏差很小,仅为随机法取点的平方根级别,尤其适用于高维空间的近似计算. 随机取点与佳点集方法取点对比如图1所示.

因此,通过佳点集方法初始化灰狼个体位置就能增加群体的多样性,在一定程度上能提高灰狼的全局搜索能力,并加快算法的收敛速度.

### 3.1.2 非线性参数控制

群体智能优化算法中的一个关键问题是协调全局探索能力与局部开发能力. 全局探索能力与优化的稳定性相关,而局部开发能力影响优化算法的收敛速度. GWO 算法中的参数  $A$  对平衡其全局搜索能力与局部开发能力起着关键作用. 当  $|A| > 1$  时,灰狼将扩大搜索范围,即体现为 GWO 算法的全局探索能力;当  $|A| < 1$  时,灰狼将缩小搜索范围,在局部进行精细开采,即体现为算法的局部开发能力. 经典灰狼算法  $A$  的值是随着迭代次数由 2 到 0 线性变化. Mittal 等<sup>[29]</sup> 的研究表明,对参数  $A$  进行非线性变换有助于更好的寻优性能. 本文运用三角余弦函数对公式(8)中的参数  $a$  进行非线性变换,如公式(18)所示:

$$a = \cos\left(\frac{t}{\text{Maxiter}}\pi\right) + 1, \quad (18)$$

其中,  $t$  为当前的迭代次数,  $\text{Maxiter}$  为最大迭代次数.

### 3.1.3 基于权重的灰狼位置更新

在灰狼体更新位置过程中,每次迭代都根据适应度值选出最优的前三头狼,且当前适应度值越优越可能接近最优解. 因此,可以根据  $\alpha, \beta, \delta$  狼的适应度值,设置其不同的权重,并突出了  $\alpha$  狼的主导作用,这样就能使得算法尽快收敛. 因此,将公式(13)中位置更新增加前三头狼的不同的权重设置,如公式(19)所示:

$$X(t+1) = \frac{1}{\frac{1}{f_\alpha} + \frac{1}{f_\beta} + \frac{1}{f_\delta}} \left( \frac{X_1}{f_\alpha} + \frac{X_2}{f_\beta} + \frac{X_3}{f_\delta} \right), \quad (19)$$

其中,  $t$  是迭代次数;  $\frac{1}{f_\alpha}, \frac{1}{f_\beta}, \frac{1}{f_\delta}$  分别是当前  $\alpha, \beta, \delta$  狼位置的权重值.

如此,在通过佳点集的灰狼个体位置初始化,使得个体位置分布更均匀,增加种群初始值多样性;对参数  $A$  进行非线性变换后,增强算法的全局搜索能力;设置引领狼的不同权重,加快算法的收敛速度. 后续的实验证明,改进后的灰狼优化算法能够增强狼群的全局搜索的稳定性,且收敛速度相对较快.

### 3.1.4 改进灰狼优化算法(IGWO)的有效性验证

为验证 IGWO 的有效性,本文从文献[30]中选取前 12 个高维测试函数进行测试,具体函数表达式详见参考文献. 将改进后 IGWO 与经典灰狼算法优化算法(GWO)、当前较为流行的基于差分进化改进灰狼优化算法(DEGWO)<sup>[30,31]</sup>,以及应用较广的粒子群算法(PSO)进行对比. 实验环境为: i7-3537 CPU, 2.50 GHZ, 四核,内存 8 G, 操作系统为 Windows 7, 64 位, 软件为 Matlab 2018b. 设置灰狼种群规模  $N = 30$ , 迭代 300 次; PSO 算法中  $C1 = C2 = 2$ ,  $w = 0.75$ . 对 12 个测试函数优化的收敛曲线分别如表 1 所示.

由表 1 的对 12 个函数优化的收敛曲线图可以看出,除函数  $f_8$  外,经改进的灰狼优化算法 IGWO 均有明显的突出表现,且收敛速度相对较快. 为进一步量化比较算法的性能,对上述四种优化算法均循环 30 次,求其运行结果的最优值(Fmin)、30 次循环的平均最优值(Mean)及其标准差(Std),得到结果数据如表 2 所

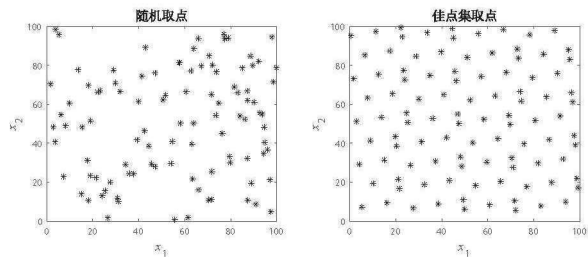
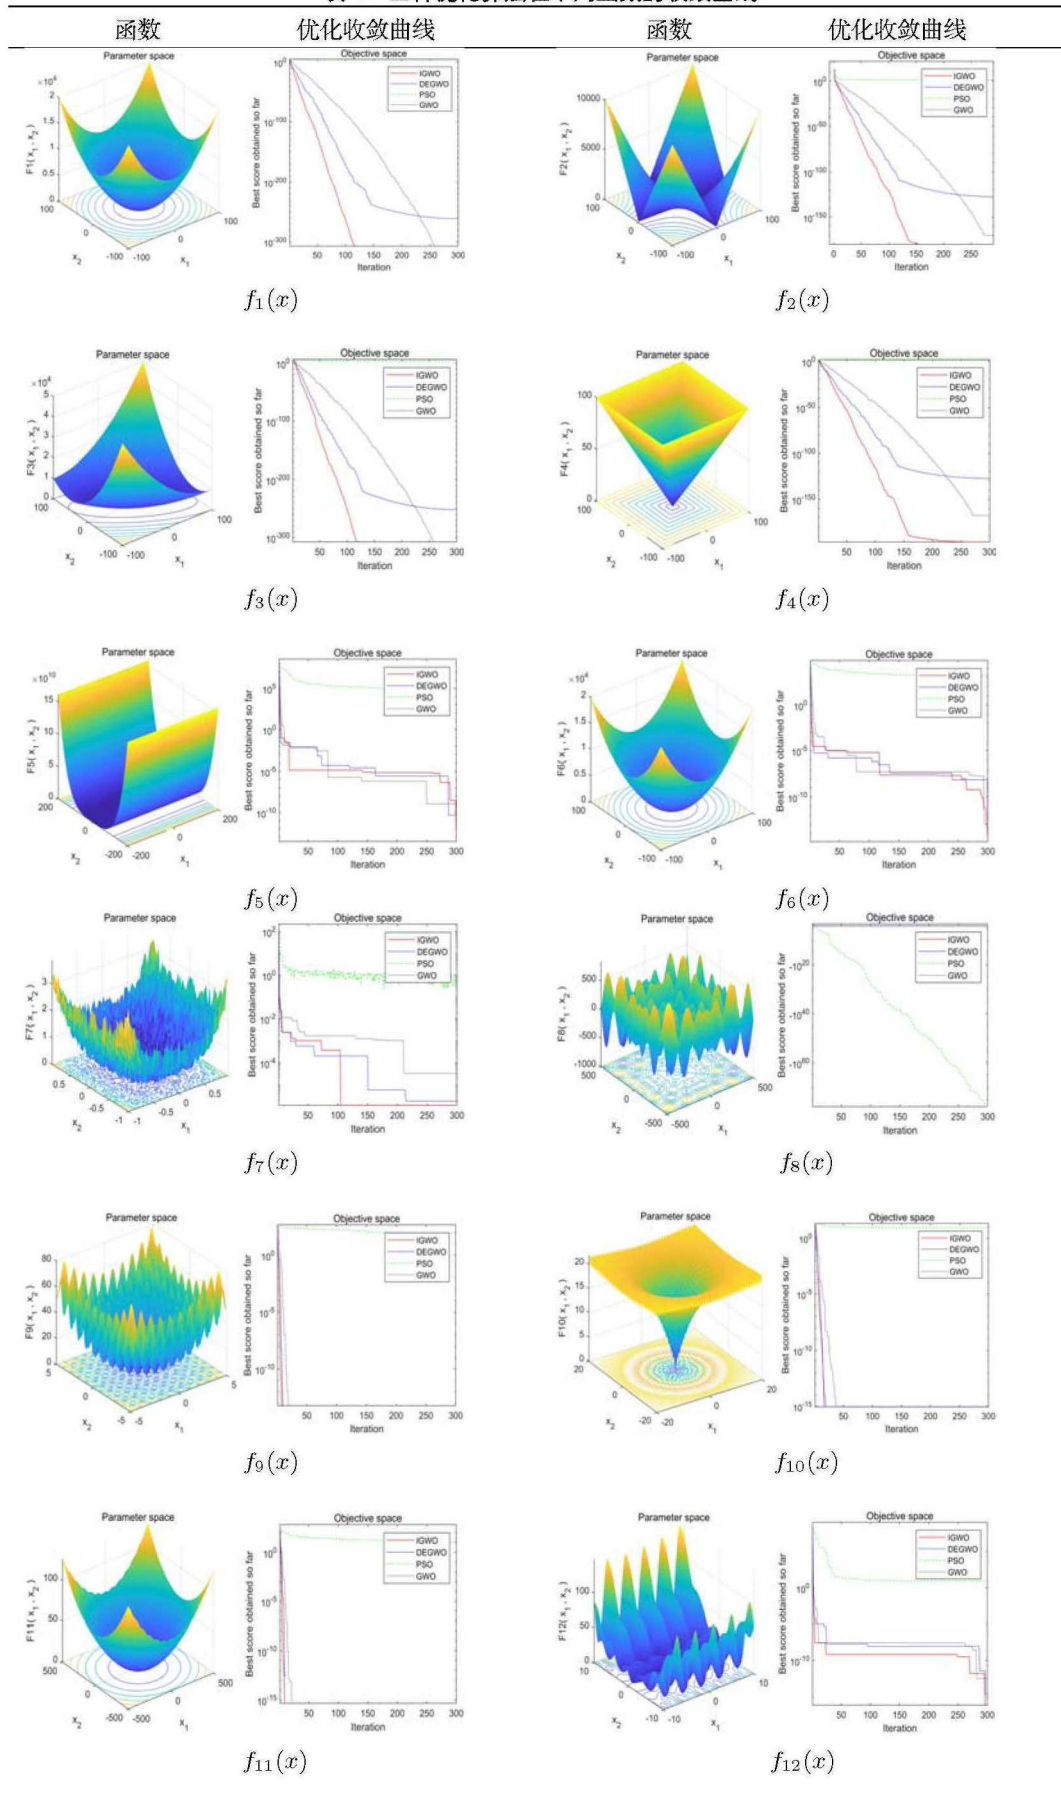


图1 佳点集取点法与随机取点法对比

表 1 四种优化算法在不同函数的收敛曲线



示. 由表 2 可以看出, 经过 30 轮求解, IGWO 与 GWO 在  $f_1$  上求得的最小值和标准差都为 0, 但在均值的精度上, IGWO 远高于 GWO, 同时也明显优于 DEGWO 和 PSO; 对于函数  $f_2, f_3, f_4, f_6, f_{12}$  的优化, IGWO 求得的三个指标都明显优于 GWO, DEGWO 和 PSO 算法; IGWO 在函数  $f_5, f_7$  的均值和标准差与 GWO、

表 2 测试函数的统计结果

函数	维数 (dim)	变量值域	优化算法	最小值 (Fmin)	均值 (Mean)	标准差 (Std)
$f_1$	30	[-100, 100]	IGWO	0	$7.3717 \times 10^{-310}$	0
			DEGWO	$5.5495 \times 10^{-262}$	$9.6780 \times 10^{-200}$	0
			GWO	0	$1.3872 \times 10^{-240}$	0
			PSO	$8.7383 \times 10^2$	$2.4111 \times 10^3$	$7.8316 \times 10^2$
$f_2$	30	[-10, 10]	IGWO	0	$8.5514 \times 10^{-310}$	0
			DEGWO	$1.4559 \times 10^{-252}$	$7.9337 \times 10^{-190}$	0
			GWO	$4.3336 \times 10^{-171}$	$9.4812 \times 10^{-111}$	$5.1058 \times 10^{-110}$
			PSO	$2.0305 \times 10^1$	$2.7560 \times 10^1$	$5.5038 \times 10^0$
$f_3$	30	[-100, 100]	IGWO	0	$8.5514 \times 10^{-310}$	0
			DEGWO	$1.4559 \times 10^{-252}$	$7.9337 \times 10^{-190}$	0
			GWO	0	$3.9797 \times 10^{-249}$	0
			PSO	$1.6304 \times 10^3$	$4.0515 \times 10^3$	$1.4975 \times 10^3$
$f_4$	30	[-100, 100]	IGWO	$3.1474 \times 10^{-197}$	$6.7511 \times 10^{-152}$	$3.6354 \times 10^{-151}$
			DEGWO	$4.2865 \times 10^{-128}$	$6.2749 \times 10^{-104}$	$2.3386 \times 10^{-103}$
			GWO	$1.5314 \times 10^{-168}$	$1.3744 \times 10^{-114}$	$7.4012 \times 10^{-114}$
			PSO	$1.4139 \times 10^1$	$2.2775 \times 10^1$	$3.5306 \times 10^0$
$f_5$	30	[-30, 30]	IGWO	$1.7297 \times 10^{-12}$	$4.7845 \times 10^0$	$1.0699 \times 10^1$
			DEGWO	$3.2034 \times 10^{-10}$	$7.6552 \times 10^0$	$1.2695 \times 10^1$
			GWO	$1.2680 \times 10^{-9}$	$1.9138 \times 10^0$	$7.1608 \times 10^0$
			PSO	$6.2441 \times 10^4$	$4.4704 \times 10^5$	$3.5541 \times 10^5$
$f_6$	30	[-100, 100]	IGWO	$1.2601 \times 10^{-15}$	$3.9835 \times 10^{-12}$	$7.6584 \times 10^{-12}$
			DEGWO	$2.6290 \times 10^{-13}$	$1.7425 \times 10^{-9}$	$3.5864 \times 10^{-9}$
			GWO	$1.1556 \times 10^{-13}$	$1.4639 \times 10^{-9}$	$1.9106 \times 10^{-9}$
			PSO	$1.5143 \times 10^3$	$2.6400 \times 10^3$	$6.9567 \times 10^2$
$f_7$	30	[-1.28, 1.28]	IGWO	$1.0976 \times 10^{-6}$	$1.4517 \times 10^{-4}$	$1.1034 \times 10^{-4}$
			DEGWO	$1.7123 \times 10^{-6}$	$2.0216 \times 10^{-4}$	$1.5836 \times 10^{-4}$
			GWO	$3.2114 \times 10^{-5}$	$2.2049 \times 10^{-4}$	$2.7718 \times 10^{-4}$
			PSO	$2.2398 \times 10^{-1}$	$7.2870 \times 10^{-1}$	$3.2695 \times 10^{-1}$
$f_8$	30	[-500, 500]	IGWO	$-1.2569 \times 10^4$	$-1.2451 \times 10^4$	$6.3781 \times 10^2$
			DEGWO	$-1.2569 \times 10^4$	$-1.1977 \times 10^4$	$1.3242 \times 10^3$
			GWO	$-1.2569 \times 10^4$	$-1.1267 \times 10^4$	$1.7122 \times 10^3$
			PSO	$-7.1183 \times 10^{77}$	$-2.3729 \times 10^{76}$	$1.2778 \times 10^{77}$
$f_9$	30	[-500, 500]	IGWO	0	0	0
			DEGWO	0	0	0
			GWO	0	0	0
			PSO	$8.6001 \times 10^1$	$1.3626 \times 10^2$	$2.4994 \times 10^1$
$f_{10}$	30	[-500, 500]	IGWO	$8.8818 \times 10^{-16}$	$8.8818 \times 10^{-16}$	0
			DEGWO	$8.8818 \times 10^{-16}$	$8.8818 \times 10^{-16}$	0
			GWO	$8.8818 \times 10^{-16}$	$8.8818 \times 10^{-16}$	0
			PSO	$8.4426 \times 10^0$	$1.1871 \times 10^1$	$1.2546 \times 10^0$
$f_{11}$	30	[-500, 500]	IGWO	0	0	0
			DEGWO	0	0	0
			GWO	0	0	0
			PSO	$1.1103 \times 10^1$	$2.1404 \times 10^1$	$7.3215 \times 10^0$
$f_{12}$	30	[-500, 500]	IGWO	$6.7879 \times 10^{-17}$	$9.9029 \times 10^{-13}$	$1.6525 \times 10^{-12}$
			DEGWO	$2.1820 \times 10^{-15}$	$1.3544 \times 10^{-10}$	$1.9525 \times 10^{-10}$
			GWO	$3.1216 \times 10^{-13}$	$2.2975 \times 10^{-10}$	$3.9887 \times 10^{-10}$
			PSO	$8.4776 \times 10^0$	$7.0333 \times 10^1$	$1.1592 \times 10^2$



DEGWO 接近,但其最小值相对精度更高;在函数  $f_8, f_9, f_{10}, f_{11}$  上, IGWO、GWO、DEGWO 求得的结果较接近. 表中数据显示, 每轮 300 次迭代寻优, IGWO 在函数  $f_1, f_2, f_3, f_9, f_{11}$  优化上均能求得全局最优解 0, 其中在函数  $f_9, f_{11}$  上求得的均值和标准差都为 0, 在函数  $f_1, f_2, f_3$  上均值的精度超过  $1 \times 10^{-310}$ , 标准差接近 0.

由此可见, 本文提出的 IGWO 具有较好的全局搜索性能, 且稳定性较好, 改进是有效的.

### 3.2 基于改进灰狼优化支持向量机回归 (IGWO-SVR) 的网络舆情预测

基于改进灰狼优化支持向量机回归 (IGWO-SVR) 的网络舆情预测具体步骤如下:

Step 1: 舆情数据导入和归一化;

Step 2: 利用 3.1.1 的佳点集方法初始化灰狼个体的初始坐标位置坐标;

Step 3: 设置算法参数: 灰狼种群规模  $N$ , 最大迭代次数  $\text{Maxiter}$ , 待优化参数个数 (即灰狼位置坐标维度  $\text{dim}$ ) 和参数取值范围  $[\text{lb}, \text{ub}]$ ;

Step 4: 以灰狼个体的坐标分量作为对应的待优化的超参数  $(C, g)$  的值, 代入到 SVR 训练模型进行训练, 计算适应度值 (目标值为均方差 (MSE) 最小);

Step 5: 将适应度最小的前三只狼分别选为  $\alpha, \beta, \delta$  狼, 其对应的位置分别为  $X_\alpha, X_\beta, X_\delta$ ;

Step 6: 更新参数  $a, C^*, A$  的值 (公式 (18)), 更新每只灰狼个体位置 (公式 (19));

Step 7: 重复 Step 4 到 Step 6, 直到达到最大迭代次数;

Step 8: 将得到的最佳超参数  $(C, g)$  用于 IGWO-SVR 模型预测;

Step 9: 求出预测值, 并进行相关计算输出.

完整算法流程图如图 2 所示.

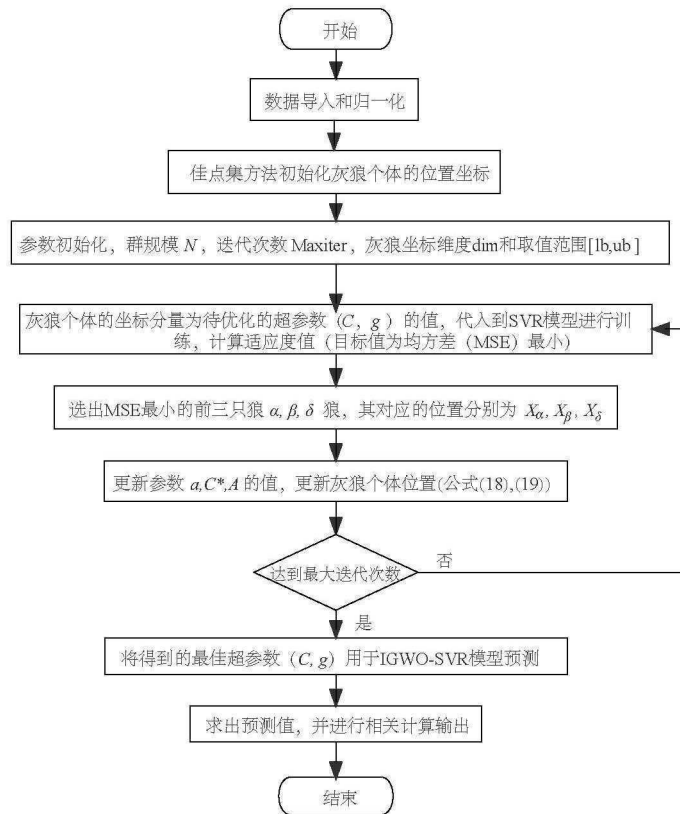


图 2 IGWO-SVR 预测模型流程图

## 4 实证研究

### 4.1 实验条件

本文实验机器为 i7 四核, 内存 8 G, 操作系统为 Windows 7, 软件为 Matlab 2018b, 数据采集用 Python 编写的网络爬虫获取百度指数 (PC+ 移动端) 数据. 评价指标分别为均方根误差 (RMSE)、平均绝对百分比误差 (MAPE)、回归模型的决定系数 ( $R^2$ ), 如公式 (20)~(22) 所示.

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - y_i^*)^2}, \quad (20)$$

$$\text{MAPE} = \frac{1}{n} \left( \frac{|y_i - y_i^*|}{y_i} \right), \quad (21)$$

$$R^2 = \frac{\text{SSR}}{\text{SST}} = \sum_{i=1}^n \frac{(y_i^* - \bar{y})^2}{(y_i - \bar{y})^2}. \quad (22)$$

### 4.2 实验结果与分析

SVR 模型的超参数设置在网络舆情预测结果中起着关键作用, 粒子群优化算法及其各种改进版在 SVR 的超参数寻优中运用较为广泛. 本文首先以“新冠肺炎”舆情事件为案例验证 IGWO-SVR 模型在网络舆情预测中的有效性, 并对比基于粒子群优化支持向量回归 (PSO-SVR)、经典灰狼算法优化支持向量回归 (GWO-SVR) 以及基于差分进化改进灰狼优化支持向量回归 (DEGWO-SVR) 在网络舆情预测中的应用结果.



“新冠肺炎”疫情是2020年全球重大公共卫生事件,疫情已经蔓延到全球大多数国家,给世界人民造成巨大的健康威胁与不可估量的经济损失.截至本文实验时间节点,“新冠肺炎”相关的网络舆情引起了全球人民的广泛关注,并且还在持续发酵和传播中.利用网络爬虫获取百度指数(PC+移动端)数据,舆情传播时间序列从2019年12月30日至2020年2月12日总共45天,如图3所示.按3:1划分数据集,取前33天为训练集数据,后12天为测试集数据,用前三天数据预测后一天的数值.

设置IGWO-SVR、DEGWO-SVR、GWO-SVR三种灰狼优化算法的参数,灰狼个体数量为30,优化迭代500次;PSO-SVR种群数量为100,迭代500次;待优化超参数( $C$ 和 $g$ )的取值范围均为 $[0.01, 100]$ .为验证不同模型算法解的预测结果和稳定性,对四种模型运行均循环20次后取平均,得到四种模型预测结果对比如图4所示,预测相对误差如图5所示,各指标平均值如表3所示.

绘制IGWO-SVR模型对超参数 $C, g$ 寻优的过程图如图6所示.运行得到的最优解为: $C = 0.0302$ ,  $g = 1.6143$ ,此时对应 $RMSE = 6.7025(*10^3)$ ,  $MAPE = 3.482\%$ ,  $R^2 = 95.976\%$ .

通过图表数据的比较可以看出,IGWO-SVR模型的各个评价指标均值都非常接近所能求得的最优值,显示了其较为稳定的全局寻优性能,其中,IGWO-SVR模型求得的指标 $RMSE(*10^3) = 6.7034$ ,低于GWO-SVR求得的结果12.3%,低于DEGWO-SVR的41.2%,低于PSO-SVR的51.4%;指标 $MAPE(\%) = 3.9488$ ,低于GWO-SVR的18.2%,低于DEGWO-SVR的43.3%,低于PSO-SVR的52.6%;回归系数 $R^2 = 95.976\%$ ,高过GWO-SVR模型的0.176%,略低于DEGWO-SVR的0.087%,高于PSO-SVR的1.194%.数据结果表明,IGWO-SVR模型的三个评价指标均优于GWO-SVR模型,并且显著优于PSO-SVR模型.对比于DEGWO-SVR模型,IGWO-SVR模型除了在回归决定系数( $R^2$ )略低DEGWO-SVR模型,但在其他两个指标均显著优于后者.由此可见,优化后的IGWO-SVR模型有相对较好的网络舆情预测性能.




图3 “新冠肺炎”舆情搜索指数时间序列

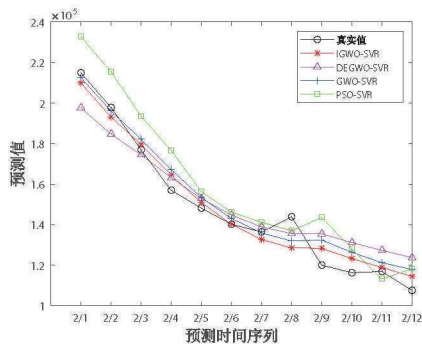


图4 舆情预测结果值比较

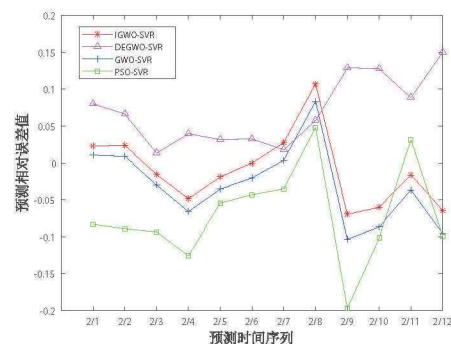


图5 预测相对误差值比较




图6 IGWO-SVR模型舆情预测对超参数( $C, g$ )的寻优

表3 四种优化算法舆情预测模型评价指标比较

优化算法	RMSE ( $*10^3$ )	MAPE (%)	$R^2$ (%)
IGWO-SVR	6.703	3.9488	95.976
DEGWO-SVR	11.403	6.9644	96.060
GWO-SVR	7.6436	4.8326	95.807
PSO-SVR	13.804	8.3367	94.843

4.3 与其他网络舆情预测方法比较

为进一步验证模型的性能, 本文选取文献 [6] 中关于“反腐”、“中国梦”、“世界杯”、“食品安全”四个舆情热点话题的前 40 天时间序列数据 (如图 7), 运用 IGWO-SVR 模型, 对比 GWO-SVR、布谷鸟优化支持向量回归 (CO-SVR, 文献 [7])、改进粒子群优化 BP 神经网络 (IPSO-BPNN, 文献 [7]) 以及文献 [6] 在网络舆情预测的结果. 实验结果如表 4 所示.

由表 4 可知, 对比其他三种预测方法, IGWO-SVR 舆情预测模型在四个舆情话题预测结果均表现出良好的结果, 且预测精度较好, 误差变化不大. 同时, 对比文献 [6], 在样本量只选取其中三分之一的情况下, 四个舆情主题中有三个预测结果的 RMSE 指标低于文献 [6] 的指标值, 取得较好的预测结果. 可以看出, IGWO-SVR 舆情预测模型有较好的性能表现.

通过上述实验可以发现, IGWO-SVR 模型在小样本网络舆情发展趋势预测中是有效的, 具有良好的性能, 求解结果相对稳定.




图 7 四个舆情热点话题搜索指数时间序列

表 4 不同网络舆情预测算法对四个舆情热点话题预测结果

舆情话题	模型	RMSE ( $\times 10^2$ )	MAPE (%)	$R^2$ (%)
反腐	IGWO-SVR	0.2681	7.1225	91.726
	GWO-SVR	0.2755	7.2644	90.060
	CO-SVR	0.2812	7.8326	90.504
	IPSO-BPNN	0.3009	10.3367	88.127
中国梦	IGWO-SVR	0.2681	7.1225	91.726
	GWO-SVR	0.2755	7.2644	90.060
	CO-SVR	0.2812	7.8326	90.504
	IPSO-BPNN	0.3009	10.3367	88.127
世界杯	IGWO-SVR	0.3074	7.9488	90.365
	GWO-SVR	0.3203	8.9642	88.012
	CO-SVR	0.3126	9.0351	88.525
	IPSO-BPNN	0.3141	8.3541	89.117
食品安全	IGWO-SVR	0.2773	7.8152	91.154
	GWO-SVR	0.2903	8.2241	89.231
	CO-SVR	0.2936	8.1331	90.192
	IPSO-BPNN	0.3154	9.2315	90.643

5 结论

网络舆情形成与传播受到众多因素的影响, 其内部机理非常复杂, 舆情热度趋势演化具有无规则、不确定性等特点, 对网络舆情发展趋势的及时监测与有效管控是公共安全领域的重大任务之一. 支持向量回归模

型在小样本预测中有较为突出的优势,但模型的超参数设置直接影响到模型预测结果的精确度和稳定性.本文通过佳点集初始化灰狼个体位置,使得种群多样化;非线性参数控制策略,使得灰狼在全局探索能力得到加强,避免了灰狼在探索过程中过早地陷入局部最优;同时,在灰狼的移动过程中考虑引领狼  $\alpha$ ,  $\beta$ ,  $\delta$  的不同权重赋值,使得优化算法能够较快地收敛到全局最优解.进而构建改进灰狼优化支持向量回归 (IGWO-SVR) 的网络舆情预测模型,并通过多个网络舆情的小样本数据实证研究该模型的有效性.对比实验结果显示,本文所构建的 IGWO-SVR 模型在网络舆情趋势的预测中,有较为突出的准确性与稳定性.当然,本文算法的有效性还需要进一步通过大量的实例验证,从而为政府舆情管控部门提供较好的决策参考.

网络舆情预测是系统完善舆情预测预警机制,科学管控网络舆情的重要环节.在此背景下,大数据环境下舆情相关信息的精确抽取,多种预测模型的融合运用以及舆情模糊信息的不确定性决策等都值得深入研究和实践.

## 参考文献

- [1] 陈羽中,方明月,郭文忠.基于小波变换与差分自回归移动平均模型的微博话题热度预测[J].模式识别与人工智能,2015,28(7): 586-594.  
Chen Y Z, Fang M Y, Guo W Z. Topic popularity prediction of microblog based on wavelet transformation and ARIMA[J]. Pattern Recognition and Artificial Intelligence, 2015, 28(7): 586-594.
- [2] 何建民,李雪.面向微博舆情演化分析的隐马尔科夫模型研究[J].情报科学,2016, V34(4): 7-12.  
He J M, Li X. A hidden Markov model research in the microblog public opinion evolution analysis[J]. Information Science, 2016, V34(4): 7-12.
- [3] 王宁,赵胜洋,单晓红.基于灰色系统理论的网络舆情预测与分级方法研究[J].情报理论与实践,2019, 42(2): 120-126.  
Wang N, Zhao S Y, Shan X H. Method of network public opinion prediction and grading based on grey system theory[J]. Information Information Studies: Theory & Application, 2019, 42(2): 120-126.
- [4] 田世海,孙美琪,张家毓.基于贝叶斯网络的自媒体舆情反转预测[J].情报理论与实践,2019, 42(2): 127-133.  
Tian S H, Sun M Q, Zhang J Y. Prediction of we-media public opinion reversion based on bayesian network[J]. Information Studies: Theory & Application, 2019, 42(2): 127-133.
- [5] 杨茂青,谢健民,秦琴,等.基于RF算法的突发事件网络舆情演化预测分析[J].情报科学,2019, 37(7): 95-100.  
Yang M Q, Xie J M, Qin Q, et al. Prediction for the evolution of emergency network public opinion based on RF algorithm[J]. Information Science, 2019, 37(7): 95-100.
- [6] 魏德志,陈福集,郑小雪.基于混沌理论和改进径向基函数神经网络的网络舆情预测方法[J].物理学报,2015, 64(11): 52-59.  
Wei D Z, Chen F J, Zheng X X. Internet public opinion chaotic prediction based on chaos theory and improved radial basis function in neural network[J]. Acta Physica Sinica, 2015, 64(11): 52-59.
- [7] 游丹丹,陈福集.基于改进粒子群和BP神经网络的网络舆情预测研究[J].情报杂志,2016, 35(8): 156-161.  
You D D, Chen F J. Research on the prediction of network public opinion based on improved PSO and BP neural network[J]. Journal of Intelligence, 2016, 35(8): 156-161.
- [8] Vapnik V, Levin E, Cun Y L, et al. Measuring the VC-dimension of a learning machine[J]. Neural Computation, 1994, 6(5): 851-876.
- [9] 陈垚,毛保华,柏赞,等.基于支持向量回归的地铁牵引能耗预测[J].系统工程理论与实践,2016, 36(8): 2101-2107.  
Chen Y, Mao B H, Bai Y, et al. Forecasting traction energy consumption of metro based on support vector regression[J]. Systems Engineering — Theory & Practice, 2016, 36(8): 2101-2107.
- [10] Mehrnoosh K, Mohammad H R. Intelligent sliding mode adaptive controller design for wind turbine pitch control system using PSO-SVM in presence of disturbance[J]. Journal of Control, Automation and Electrical Systems, 2020, 31(3): 912-925.
- [11] 王玉冬,王迪,王珊珊.高新技术企业创新资金配置风险预警的FOA-SVM模型及实证[J].系统工程理论与实践,2018, 38(11): 2852-2862.  
Wang Y D, Wang D, Wang S S. FOA-SVM model and empirical study on risk early warning of innovation fund allocation of high-tech enterprises[J]. Systems Engineering — Theory & Practice, 2018, 38(11): 2852-2862.
- [12] 戴臻.布谷鸟算法优化支持向量机的网络热点话题预测[J].计算机应用与软件,2014, 31(4): 330-333.  
Dai Z. Internet hot topics prediction based on support vector machine optimized by cuckoo search algorithm[J]. Computer Applications and Software, 2014, 31(4): 330-333.
- [13] Mirjalili S, Mirjalili S M, Lewis A, et al. Grey wolf optimizer[J]. Advances in Engineering Software, 2014: 46-61.
- [14] Saremi S, Mirjalili S Z, Mirjalili S M, et al. Evolutionary population dynamics and grey wolf optimizer[J]. Neural Computing and Applications, 2015, 26(5): 1257-1263.

- [15] Eswaramoorthy S, Sivakumaran N, Sekaran S, et al. Grey wolf optimization based parameter selection for support vector machines[J]. COMPEL — The International Journal for Computation and Mathematics in Electrical and Electronic Engineering, 2016, 35(5): 1513–1523.
- [16] Mustafa Z, Sulaiman M H, Kahar M N, et al. Training LSSVM with GWO for price forecasting[C]// International Conference on Informatics Electronics and vision, 2015: 1–6.
- [17] Mustafa Z, Sulaiman M H, Kahar M N, et al. LS-SVM hyper-parameters optimization based on GWO algorithm for time series forecasting[C]// International Conference on Software Engineering and Computer Systems, 2015: 183–188.
- [18] Elhariri E, ElBendary N, Hassanien A E. A hybrid classification model for EMG signals using grey wolf optimizer and SVMs[M]// The 1st International Conference on Advanced Intelligent System and Informatics (AISII2015), Springer International Publishing, 2016.
- [19] Elhariri E, ElBendary N, Hassanien A E, et al. Grey wolf optimization for one-against-one multi-class support vector machines[C]// Soft Computing and Pattern Recognition, 2015: 7–12.
- [20] Lang X M, Li P, Zhang B C, et al. Localization of multiple leaks in a fluid pipeline based on ultrasound velocity and improved GWO[J]. Process Safety and Environmental Protection, 2020, 137(15): 1–7.
- [21] Shabeerkhan S, Padma A. A novel GWO optimized pruning technique for inexact circuit design[J]. Microprocessors and Microsystems, 2020, 73: 102975.
- [22] Yang Y F, Yang B, Wang S L, et al. An improved grey wolf optimizer algorithm for energy-aware service composition in cloud manufacturing[J]. The International Journal of Advanced Manufacturing Technology, 2019, 105(11): 3079–3091.
- [23] 苏创, 彭锦, 李圣国. 基于不确定微分方程的网络舆情传播模型研究 [J]. 系统工程理论与实践, 2015, 35(12): 3201–3209.  
Su C, Peng J, Li S G. The internet public opinion propagation model via uncertain differential equation[J]. Systems Engineering — Theory & Practice, 2015, 35(12): 3201–3209.
- [24] Syafaruddin, Narimatsu H, Miyauchi H, et al. Optimal energy utilization of photovoltaic systems using the Non-Binary genetic algorithm[J]. Energy Technology and Policy, 2015, 2(1): 10–18.
- [25] 华罗庚, 王元. 数论在近似分析中的应用 [M]. 北京: 科学出版社. 1978: 83–86.  
Hua L G, Wang Y. Application of number theory in approximate analysis[M]. Beijing: Science Press, 1978: 83–86.
- [26] 张铃, 张钹. 佳点集遗传算法 [J]. 计算机学报, 2001, 24(9): 917–922.  
Zhang L, Zhang B. Good point set based genetic algorithm[J]. Journal of Computer Science, 2001, 24(9): 917–922.
- [27] 宁桂英, 曹敦虔, 周永权. 求解 0-1 规划问题的改进差分进化算法 [J]. 系统科学与数学, 2019, 39(1): 120–132.  
Ning G Y, Cao D Q, Zhou Y Q. Improved differential evolution algorithm for solving 0-1 programming problem[J]. Journal of Systems Science and Mathematical Sciences, 2019, 39(1): 120–132.
- [28] Kiefer J. On large deviations of the empiric D. F. of vector chance variables and a law of the iterated logarithm[J]. Pacific Journal of Mathematics, 1961, 11(2): 649–660.
- [29] Mittal N, Singh U, Sohi B S, et al. Modified grey wolf optimizer for global engineering optimization[J]. Applied Computational Intelligence and Soft Computing, 2016: 1–16.
- [30] Zhu A J, Xu C P, Li Z, et al. Hybridizing grey wolf optimization with differential evolution for global optimization and test scheduling for 3D stacked SoC[J]. Journal of Systems Engineering and Electronics, 2015, 26(2): 317–328.
- [31] Elfergany A A, Hassanien H M. Single and multi-objective optimal power flow using grey wolf optimizer and differential evolution algorithms[J]. Electric Power Components and Systems, 2015, 43(13): 1548–1559.